


Ensamble

Técnicas de Aprendizaje de Máquina

Oscar Bustos

Intuición Matemática

Capítulos sobre Ensamble



\ Capítulo 9

O'REILLY®

Third
Edition

Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow

Concepts, Tools, and Techniques
to Build Intelligent Systems

powered by



Aurélien Géron

\ Capítulo 7



Ensemble Methods for Machine Learning

Gautam Kunapuli


 MANNING

\ Capítulos 1,2,3,5

Wisdom of Crowds

¿Cómo se puede diagnosticar si un paciente tiene cáncer o no?


% Espacio opcional entre el texto y la imagen



Wisdom of Crowds

¿Cómo se puede diagnosticar si un paciente tiene cáncer o no usando IA?


% Espacio opcional entre el texto y la imagen



Evidencia empírica en los ensambles

¿Qué algoritmo de aprendizaje de máquina debo utilizar? [1]

% Espacio opcional entre el texto y la imagen



¿Qué son los Ensamblés?

- Combinación de múltiples modelos más débiles para crear un modelo más fuerte.
- Idea principal: “La sabiduría de la multitud”.
- Reducen el sesgo y la varianza.
- Mejoran la precisión y la robustez del modelo.

Resumen de Categorías de Ensamblés


Existen tres principales categorías de ensambles en machine learning: - **Parallel Homogeneous Ensembles**: Múltiples modelos del mismo tipo, entrenados con diferentes conjuntos de datos. Mejora la estabilidad y reduce la varianza. - **Parallel Heterogeneous Ensembles**: Combinación de diferentes tipos de modelos para aprovechar sus fortalezas individuales. - **Sequential Gradient Boosting Ensembles**: Modelos entrenados secuencialmente, en los que cada uno corrige los errores del anterior, logrando una mejor optimización de la función de pérdida.

Parallel Homogeneous Ensembles

Arquitectura de Ensemble Homogéneo

Cuando todos los clasificadores son del mismo tipo


% Espacio opcional entre el texto y la imagen




Bootstrapping

El bootstrapping es un método estadístico que permite generar **múltiples subconjuntos de datos** a partir del conjunto de entrenamiento original. Se basa en el muestreo con reemplazo, lo que significa que algunos ejemplos pueden aparecer más de una vez en un subconjunto, mientras que otros pueden no aparecer en absoluto.

% Espacio opcional entre el texto y la imagen



Bootstrapping



% Espacio opcional entre el texto y la imagen Entrenamiento con Bootstrapping - [2]


Bagging - Entrenamiento

Bagging - Inferencia

Comparación Bagging en Árboles de Decisión

Un único árbol de decisión (izquierda) **sobreajusta** el conjunto de entrenamiento y puede ser sensible a los valores atípicos. Un conjunto de bagging (derecha) **suaviza** los efectos de sobreajuste y las clasificaciones erróneas de varios de esos estimadores base.


% Espacioopcional entre el texto y la imagen



Bagging en Sklearn


Optimización en Bagging

% Espacioopcional entre el texto y la imagen




Características Aleatorias

Standard decision tree: all features are available from which to select the best split.



Random decision tree: only some randomly selected subsets of features are available from which to select the best split.



Random Forest: Ventajas


- Alta precisión y robustez.
- Maneja bien datos de alta dimensionalidad.
- Reduce el sobreajuste.
- Proporciona la importancia de las características.

Random Forest: Hiperparámetros Clave

- `n_estimators`: Número de árboles en el bosque.
- `max_features`: Número de características a considerar en cada división.
- `max_depth`: Profundidad máxima de los árboles.
- `min_samples_split`: Número mínimo de muestras requerido para dividir un nodo interno.

Random Forest en Sklearn

Random Forest en Sklearn




Random Forest en Sklearn

Random Forest en Sklearn

Importancia

de




Parallel Heterogeneous Ensembles


Arquitectura de Ensamble Heterogéneo

Cuando todos los clasificadores son de tipos distintos


% Espacio opcional entre el texto y la imagen



Voting



Votación




Votación Ponderada

Stacking


Entrenando un modelo que usa como entrada las salidas de otro modelo

% Espacio opcional entre el texto y la imagen




Sequential Gradient Boosting Ensembles

Arquitectura de Gradient Boosting




Arquitectura de Gradient Boosting




\ Entrenamiento secuencial de AdaBoost - [3]

Gradient Boosted Trees (GBT): Intuición




- Construye modelos de forma secuencial, donde cada nuevo modelo se enfoca en corregir los errores del modelo anterior.
- Utiliza el gradiente descendente para minimizar la función de pérdida.

Gradient Boosted Trees (GBT): Intuición



- Construye modelos de forma secuencial, en los que cada nuevo modelo se enfoca en corregir los errores del anterior.
- Utiliza el gradiente descendente para minimizar la función de pérdida.

Gradient Boosted Trees (GBT): Intuición



- Construye modelos de forma secuencial, donde cada nuevo modelo se enfoca en corregir los errores del modelo anterior.
- Utiliza el gradiente descendente para minimizar la función de pérdida.

Gradient Boosted Trees (GBT): Hiperparámetros Clave

- `n_estimators`: Número de árboles en el modelo.
- `learning_rate`: Tasa de aprendizaje, controla el impacto de cada árbol.
- `max_depth`: Profundidad máxima de los árboles.
- `subsample`: Fracción de las muestras utilizadas para entrenar cada árbol.
- `colsample_bytree`: Fracción de las características utilizadas para entrenar cada árbol.

Comparación


Random Forest vs Gradient Boosted Trees

Característica	Random Forest	Gradient Boosted Trees
Enfoque	Bagging	Boosting
Paralelización	Sí	No (secuencial)
Precisión	Alta	Muy alta
Sobreajuste	Menor riesgo	Mayor riesgo (requiere ajuste cuidadoso)
Velocidad	Rápido	Más lento (depende de la implementación)
Importancia de características	Sí	Sí

Librerías

Seleccionando Algoritmos

¿Cómo elijo el algoritmo más adecuado para mis datos?



Ensembles en Python

Ejemplo de Código: Random Forest (scikit-learn)

Ejemplo de Código: Gradient Boosting (XGBoost)

References

Bibliography

- [1] R. S. Olson, W. L. Cava, Z. Mustahsan, A. Varik, and J. H. Moore, "Data-driven advice for applying machine learning to bioinformatics problems," in *Pacific symposium on biocomputing 2018: Proceedings of the pacific symposium*, 2018, pp. 192–203.
- [2] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 3rd ed. O'Reilly Media, Inc., 2022.
- [3] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, *An introduction to statistical learning: With applications in python*. Springer Nature, 2023.