


Modelos Lineales

Técnicas de aprendizaje de máquina


Oscar Bustos


Repaso

Sklearn y Problemas de ML



Referencias de esta sesión







Etapas Clave en un Proyecto de Machine Learning

Resumen Capítulo 2 - Hands on ML (Cuaderno Colab) - Observar el panorama general. - Obtener los datos. - Explorar y visualizar los datos para obtener ideas. - Preparar los datos para los algoritmos de machine learning. - Seleccionar un modelo y entrenarlo. - Ajustar y optimizar el modelo. - Presentar la solución. - Lanzar, monitorear y mantener el sistema. https://colab.research.google.com/github/ageron/handson-ml3/blob/main/02_end_to_end_machine_learning_project.ipynb

Regresión con Modelos Lineales

¿Qué es el Aprendizaje Estadístico?


- ¿Podemos predecir los ingresos usando años de educación?
- Modelo: $\text{Ingresos} \approx f(\text{Años de Educación})$



¿Qué es el Aprendizaje Estadístico?

- ¿Podemos predecir los ingresos usando años de educación y años de experiencia?

- Modelo: $\text{Ingresos} \approx f(\text{Años de Educación, Años de Experiencia})$



\end{center}


Notación

- **Variable objetivo:**
 - Ingresos: resultado que deseamos predecir (Y)
- **Predictores:**
 - Ingresos: característica o predictor (X_1)
 - Experiencia: segunda característica (X_2)
- **Vector de entradas:** $[X_1, X_2, X_3]$
- **Modelo general:** $Y = f(X) + \epsilon$
 - ϵ : captura los errores de medición

Modelos Paramétricos: Caso Lineal

$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ - Forma funcional predefinida - Estimación de parámetros β_i - Ventaja: Simplicidad computacional

Modelos Paramétricos: Caso Lineal



$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$

\end{center}

Modelos Paramétricos: Caso Lineal

El modelo lineal es un importante ejemplo de modelos paramétrico [$f_L(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$] - Un modelo lineal es especificado en términos de $p + 1$ parámetros $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ - Estimación de parámetros ajustando los parámetros a la información de entrenamiento - Aunque casi nunca es correcto, un modelo lineal sirve como una buena aproximación interpretable a la función desconocida $f(X)$

Mínimos Cuadrados Ordinarios (OLS)

- **Objetivo:** Encontrar la mejor línea (o hiperplano) de ajuste que minimice la suma de las diferencias al cuadrado entre los valores observados y los valores predichos.
- **Formulación Matemática:**
 - Dado un conjunto de puntos de datos (x_i, y_i) , queremos encontrar los coeficientes $\beta_0, \beta_1, \dots, \beta_p$ que minimicen la siguiente función objetivo: $\sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}))^2$ donde:
 - n es el número de observaciones
 - y_i es el valor real de la variable dependiente para la i -ésima observación
 - x_{ij} es el valor de la j -ésima variable independiente para la i -ésima observación
 - $\beta_0, \beta_1, \dots, \beta_p$ son los coeficientes que queremos estimar

Mínimos Cuadrados Ordinarios (OLS)

- **Cálculo Matricial:**
 - Expresamos el modelo de regresión lineal en forma matricial como: $y = X\beta + \epsilon$ donde:
 - y es un vector columna de n valores de la variable dependiente
 - X es una matriz de diseño de $n \times (p + 1)$ que contiene los valores de las variables independientes y un vector de unos para el término de intercepción
 - β es un vector columna de $(p + 1)$ coeficientes que queremos estimar
 - ϵ es un vector columna de n errores
 - La solución de OLS para los coeficientes β se obtiene mediante la siguiente fórmula: $\beta = (X^T X)^{-1} X^T y$ donde:
 - X^T es la transpuesta de la matriz X
 - $(X^T X)^{-1}$ es la inversa de la matriz $X^T X$

Mínimos Cuadrados Ordinarios (OLS)

- **Intuición Geométrica:** OLS busca la línea que esté “más cerca” de los puntos de datos en términos de la suma de las distancias verticales al cuadrado.
- **Ventajas:**
 - Simple y computacionalmente eficiente
 - Proporciona estimaciones insesgadas de los coeficientes bajo ciertos supuestos
 - Permite realizar pruebas de hipótesis e intervalos de confianza
- **Limitaciones:**
 - Sensible a los valores atípicos

- Asume una relación lineal entre las variables independientes y dependientes
- Puede no funcionar bien con predictores altamente correlacionados

¿Por qué estimar f ?

- **Predicción:** Pronosticar ingresos futuros
- **Inferencia:**
 - ¿Qué variables afectan los ingresos?
 - Magnitud de efectos
- **Otras aplicaciones:**
 - Comparación de teorías
 - Toma de decisiones políticas

Métricas de Error en Regresión (1)

Error Cuadrático Medio (MSE): $\left[= \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{y}_i)^2 \right]$ Penaliza más los errores grandes debido a la cuadratura.


Raíz del Error Cuadrático Medio (RMSE): $\left[= \sqrt{\text{MSE}} \right]$ Más interpretable que el MSE, ya que mantiene las unidades originales.

Métricas de Error en Regresión (2)

Error Absoluto Medio (MAE): $\left[= \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{y}_i| \right]$ Menos sensible a valores atípicos que el MSE.

Porcentaje de Error Absoluto Medio (MAPE): $\left[= \frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{y}_i}{Y_i} \right| \right]$ Expresa el error en porcentaje para facilitar la comparación.

Interactividad de Regresión lineal




\begin{center}

\end{center}

https://oscar-bustos.github.io/javeriana-tallerml/regresion_lineal/mean_squared_error.html

Gradiente Descendente



Algoritmo de Gradiente Descendente

Es un método iterativo de optimización para encontrar los parámetros β que minimizan una función de costo $J(\beta)$, como por ejemplo MSE.

i Paso de actualización del Gradiente Descendente

La idea es moverse en la dirección opuesta al gradiente (que apunta hacia el mayor ascenso). La regla de actualización es:

$$\beta_{\text{siguiente}} = \beta - \eta \nabla_{\beta} J(\beta)$$

- β : Son los parámetros del modelo que queremos optimizar.
- η (eta): Es la **tasa de aprendizaje** (learning rate), un hiperparámetro que controla qué tan grande es cada paso que damos.
- $\nabla_{\beta} J(\beta)$: Es el **vector gradiente** de la función de costo. Contiene todas las derivadas parciales y apunta en la dirección de mayor incremento de la función.

Gradiente para el Error Cuadrático Medio (MSE)

i Cálculo del Vector Gradiente (Forma Vectorizada)


En lugar de calcular cada derivada parcial individualmente, usamos una fórmula eficiente que calcula todo el gradiente de una vez:

$$\nabla_{\beta} \text{MSE}(\beta) = \frac{2}{m} \mathbf{X}^T (\mathbf{X}\beta - \mathbf{y})$$


- m : Es el número total de instancias (ejemplos) en el conjunto de datos.
- $\mathbf{X}$: Es la matriz que contiene todas las características (features) de las instancias. Cada fila es una instancia.
- $\mathbf{y}$: Es el vector que contiene los valores o etiquetas reales para cada instancia.

- $\mathbf{X}^T$: Es la transpuesta de la matriz $\mathbf{X}$.

Gradiente en Lotes (Batch)




Gradiente Estocástico



Regresión Lineal en Sklearn

Tradeoffs en Modelado

- **Interpretabilidad** vs Complejidad
- **Underfitting** (muy simple) vs **Overfitting** (muy complejo)
- **Otras consideraciones:**
 - Costo computacional
 - Escalabilidad



Regularización: Ridge y Lasso

La regularización es una técnica para evitar el sobreajuste al modificar la función de costo.

i Ridge Regression (Penalización ℓ_2)

Añade el cuadrado de la norma ℓ_2 de los pesos a la función de costo.

$$J(\beta) = \text{MSE}(\beta) + \alpha \sum_{i=1}^n \beta_i^2$$

- Encoge los pesos de las características hacia cero.
- No elimina los pesos por completo (no los hace exactamente cero).


i Lasso Regression (Penalización ℓ_1)

Añade el valor absoluto (norma ℓ_1) de los pesos a la función de costo.

$$J(\beta) = \text{MSE}(\beta) + \alpha \sum_{i=1}^n |\beta_i|$$

- Puede encoger los pesos **exactamente a cero**.
- Efectivamente realiza una **selección de características**.

Regularización



\begin{center}
\end{center}

Modelos lineales (izquierda) y polinómicos (derecha), ambos con distintos niveles de regularización (Ridge).

Regresión Ridge (L2) en Sklearn


Regresión Lasso (L1) en Sklearn

Clasificación con Modelos Lineales

Clasificación y Variables Cualitativas

- Las variables cualitativas toman valores en un conjunto no ordenado C , como:
 - Color de ojos $\in \{\text{marrón, azul, verde}\}$
 - Correo electrónico $\in \{\text{spam, ham}\}$
- Dado un vector de características X y una variable respuesta cualitativa Y que toma valores en el conjunto C , la tarea de clasificación consiste en construir una función $C(X)$ que toma como entrada X y predice su valor para Y ; es decir, $C(X) \in C$.
- A menudo, estamos más interesados en estimar las probabilidades de que X pertenezca a cada categoría en C .

Ejemplo: Tarjeta de Crédito




\begin{center}
\end{center}

Modelos Lineales para Clasificación


- Regresión Logística: $P(Y=1|X) =$

\begin{cen-



ter}
\end{center}

Matriz de Confusión



\begin{center}
\end{center}

Matriz de Confusión

Matriz de Confusión: []

Permite visualizar el desempeño del modelo mostrando las predicciones correctas e incorrectas en cada categoría.

Definiciones: - **TP (True Positives):** Casos positivos correctamente identificados. - **TN (True Negatives):** Casos negativos correctamente identificados. - **FP (False Positives):** Casos negativos incorrectamente clasificados como positivos. - **FN (False Negatives):** Casos positivos incorrectamente clasificados como negativos.

Métricas de Clasificación (1)

Exactitud (Accuracy): [=] Mide la proporción de instancias correctamente clasificadas.


Precisión (Precision): [=] Indica la proporción de positivos predichos que son realmente positivos.

Métricas de Clasificación (2)

Exhaustividad (Recall): [=] Mide la capacidad del modelo para encontrar todos los positivos reales.


Puntuación F1 (F1-Score): [= 2] Media armónica entre precisión y exhaustividad, útil en conjuntos de datos desbalanceados.

Tradeoff: Precision /Recall



\begin{center}
\end{center}


Curva Precision /Recall



\begin{center}

\end{center}

Curva Receiver Operating Characteristic (ROC)



Regresión Logística en Sklearn

References

Bibliography